2026.03.03

김태훈

Advanced RAG Part 3

Query Translation: Decomposition

목차

01 **프로젝트 설명**

기존 프로젝트: RAG-Fusion을 활용한 질문 우선순위 지정 및 융합 → RAG 호출
현 프로젝트 방향성: Decomposition을 활용한 IR-CoT

02 **아키텍처 및 작동 원리**

워크 플로우1: Multi-Query 생성
워크플로우 2: Sub-Query에 대한 RAG 실행
워크플로우 3: Sub-Query의 RAG 답변을 다음 n번째 Sub-Query에 context로 활용
워크플로우 4: 최종 답변 생성

03 **구현 방법**

환경 설정: VS Code와 Jupyter Extension을 활용한 개발 환경
코드 구현: Python 기반의 단계별 라이브러리 호출 빛 프로토타입 소스 코드 가이드

04 **개선 방향**

장단점 분석: 코드 제한 분선을 통한 추후 개선 방향 제시

01 프로젝트 설명

AS-IS: Query Translation: RAG-Fusion

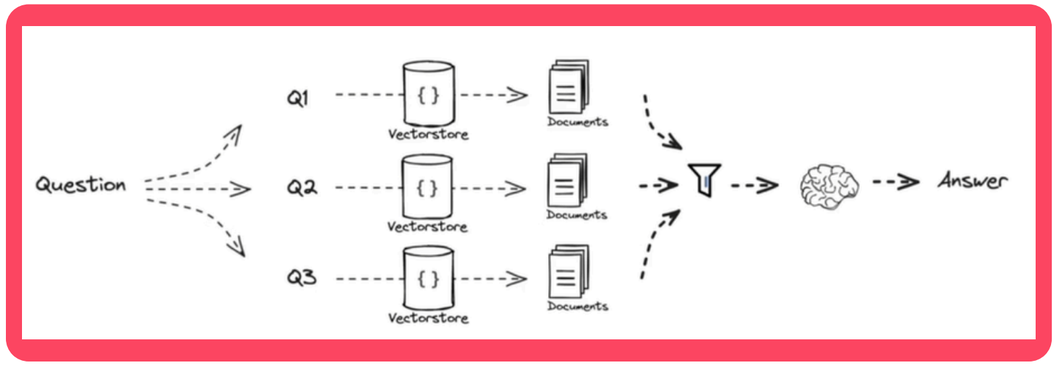

TO-BE: Query Translation: Decomposition

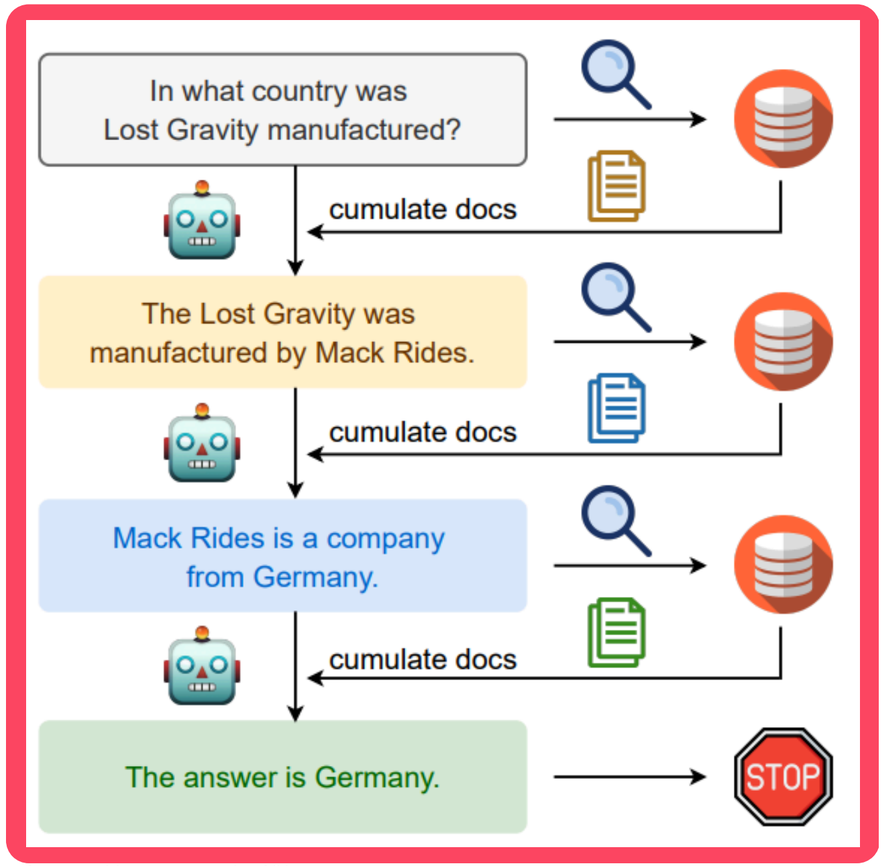

https://arxiv.org/pdf/2212.10509

02 아키텍처 및 작동 원리

워크 플로우1: Multi-Query 생성

사용자 질문 1개
↓
LLM이 동일한 질문을 3 가지 다른 관점으로 재작성
↓
["질문 버전1", "질문 버전2", "질문 버전3"]

워크 플로우2: Sub-Query에 대한 RAG 실행

질문 순서대로 RAG 실행
↓
첫번째 RAG를 통한 LLM의 답변이 다음 질문에 대한 추가 자료로 사용

워크 플로우 3: Sub-Query의 RAG 답변을
다음 n번째 Sub-Query에 context로 활용

Q1→ RAG → Q1 ans
↓
Q1 ans + Q2 → RAG → Q2 ans
↓
Q2 ans + Q3 → RAG → final Ans

워크 플로우4: 최종 답변 생성

종합된 문서들을 context로 사용
↓
LLM이 context + 원본 질문을 바탕으로 최종 답변 생성

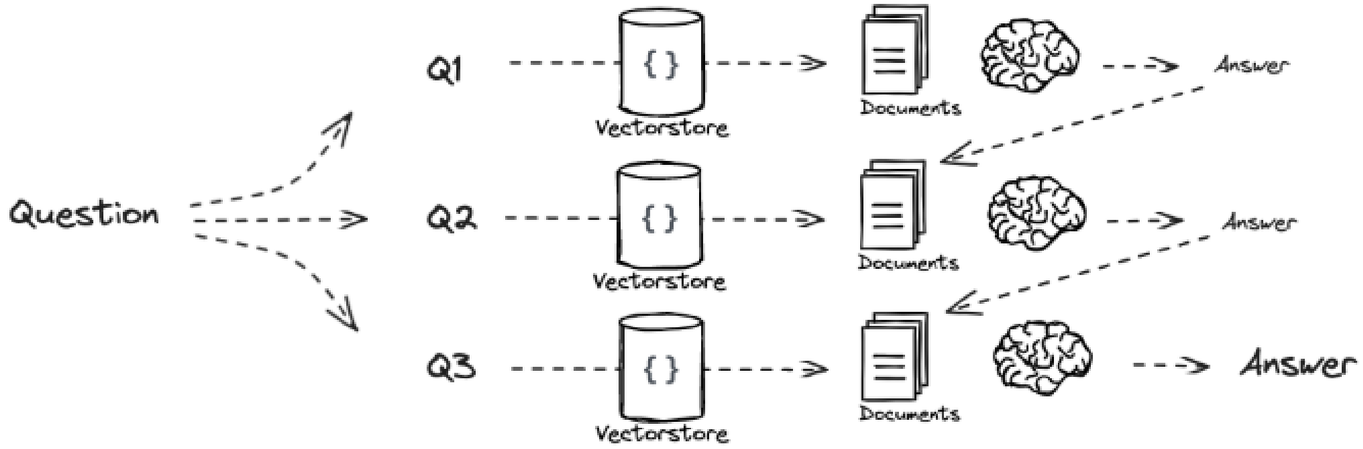

03 코드 구현

https://github.com/KimHoon98/RAG-Implementation

0.) README를 통해 페이지에 대한 설명, 프로젝트 순서를 확인할 수 있습니다.
1.) 각 파일마다 README 파일이 첨부 되어있으니 참조하시면 됩니다.
2.) 해당 파워포인트에 대한 설명은 Note explanation Section 참조하세요.

Document 내용에 대한 제한

ex1.) 삼성전자가 분기 실적 발표에서 통상적으로 공시하는 핵심 재무 지표들은 무엇인가요?

ex2.) 2025년 4분기 삼성전자의 실적에 영향을 미칠 수 있는 예상 시장 상황과 트렌드에는 어떤 것들이 있나요?

ex3.) 삼성전자의 2025년 4분기 실적과 관련하여 분석가들이 특히 주목하고 있는 특정 제품이나 사업 부문이 있나요?

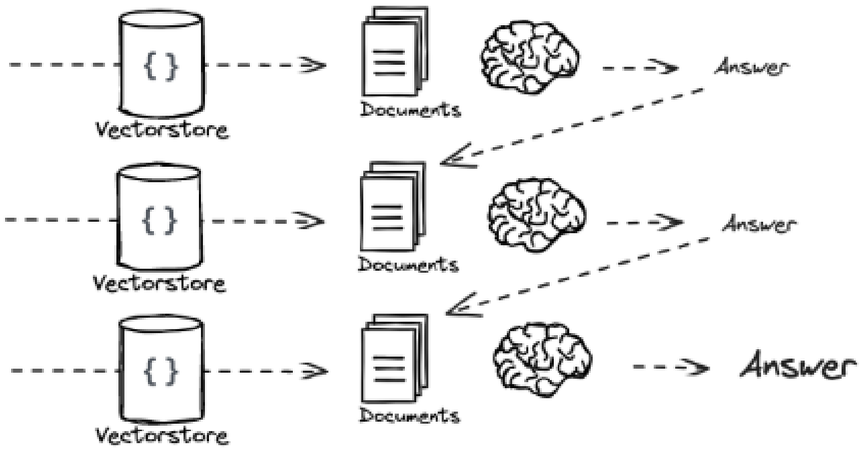

Q1→ RAG → Q1 ans
↓
Q1 ans + Q2 → RAG → Q2 ans
↓
Q2 ans + Q3 → RAG → final Ans

흐름 구조에서 Q1,Q2,Q3의 질문 형태가 비슷하다는것을 전제하에 이 알고리즘을 활용하는것이 가장 효율적인 답변을 줄 것으로 예상